

Predicción de Abandono de Usuarios en Plataformas de Streaming Musical: Análisis de Factores y Modelos de Machine Learning

Mateo Gaviria Ruiz, Jose Luis Murillo Fernandez, Stiven Alipio Berrío
Estudiantes de Ingeniería de Sistemas
Universidad de Antioquia
Medellín, Colombia

Resumen—El abandono de usuarios (churn) es un desafío relevante para plataformas digitales basadas en suscripción, ya que afecta la retención de clientes y la estabilidad de los ingresos recurrentes. Este proyecto analiza el churn en usuarios de Spotify utilizando un conjunto de datos público de Kaggle compuesto por 8.000 registros y 12 variables relacionadas con información demográfica, tipo de suscripción, comportamiento de escucha, uso de dispositivos, anuncios y escucha sin conexión.

El objetivo es identificar variables asociadas con la cancelación o inactividad de los usuarios y plantear una aproximación de aprendizaje automático para predecir si un usuario abandonará o no la plataforma. Dado que la base de datos no incluye una variable explícita sobre el motivo de cancelación, el análisis se enfoca en relaciones y patrones observables, sin asumir causalidad directa.

En esta primera etapa se describe el problema, la composición del conjunto de datos, el paradigma de aprendizaje supervisado y una revisión inicial del estado del arte sobre predicción de churn en servicios digitales.

Index Terms—churn, Spotify, aprendizaje automático, clasificación binaria, retención de usuarios.

I. INTRODUCCIÓN

Las plataformas de streaming musical han transformado la forma en que los usuarios acceden y consumen contenido digital. Spotify, por ejemplo, opera bajo un modelo que combina usuarios gratuitos con publicidad y usuarios de suscripción premium, por lo que la permanencia y participación continua de los usuarios representa un aspecto importante para la sostenibilidad del servicio [1]. En este contexto, el abandono de usuarios, conocido como churn, constituye un problema relevante, ya que puede afectar la retención de clientes, los ingresos recurrentes y las estrategias de fidelización.

La predicción de churn ha sido ampliamente abordada mediante técnicas de aprendizaje automático, debido a que permite identificar usuarios con mayor probabilidad de abandonar un servicio y apoyar la toma de decisiones en estrategias de retención [5]. En plataformas de streaming musical, el comportamiento de uso resulta especialmente importante, ya que variables como el tiempo de escucha, la cantidad de canciones reproducidas, la tasa de omisión (skip rate), el tipo de dispositivo y el uso de funcionalidades específicas pueden aportar información sobre el nivel de interacción del usuario con la plataforma [3], [4].

Este proyecto aborda el análisis y la predicción del churn en usuarios de Spotify utilizando el conjunto de datos público *Spotify Analysis Dataset 2025*, disponible en Kaggle. Este dataset contiene información demográfica, tipo de suscripción, comportamiento de escucha, exposición a anuncios, uso de dispositivos y una variable objetivo denominada `is_churned`, que indica si el usuario abandonó o no la plataforma [2]. Dado que la base de datos no incluye una variable explícita sobre el motivo de cancelación, el propósito del trabajo no es establecer causas directas, sino analizar patrones asociados al abandono y plantear una solución de aprendizaje supervisado para clasificar usuarios activos y usuarios que abandonaron.

El documento se organiza de la siguiente manera: la Sección II presenta la descripción del problema, la composición del conjunto de datos, las variables disponibles, las consideraciones iniciales de preprocesamiento y el paradigma de aprendizaje seleccionado. La Sección III expone una revisión inicial del estado del arte sobre predicción de churn en servicios digitales y modelos de aprendizaje automático aplicados a problemas similares.

II. DESCRIPCIÓN DEL PROBLEMA

II-A. Contexto y utilidad de una solución basada en ML

El abandono de usuarios, conocido como churn, es un problema relevante para plataformas digitales como Spotify, ya que afecta la retención de usuarios y la estabilidad de los ingresos generados por suscripciones y publicidad [1]. En este proyecto, el churn se aborda como un problema de clasificación binaria, donde se busca predecir si un usuario abandonará o no la plataforma a partir de variables demográficas, tipo de suscripción y comportamiento de uso [2].

Una solución basada en Machine Learning permite identificar patrones asociados al abandono y apoyar futuras estrategias de retención. Sin embargo, como el conjunto de datos no incluye una variable explícita sobre el motivo de cancelación, el análisis no busca establecer causas directas, sino estudiar relaciones entre las características disponibles y la variable objetivo `is_churned`.

II-B. Conjunto de datos

El conjunto de datos utilizado corresponde a *Spotify Analysis Dataset 2025*, disponible en Kaggle [2]. La base contiene 8.000 registros, donde cada fila representa un usuario. Las variables incluyen información demográfica, tipo de suscripción, comportamiento de escucha, dispositivo utilizado, exposición a anuncios, escucha sin conexión y la variable objetivo *is_churned*.

El problema se formula como una tarea de clasificación binaria, donde *is_churned* = 0 representa usuarios activos y *is_churned* = 1 usuarios que abandonaron. La distribución inicial muestra 5.929 usuarios activos y 2.071 usuarios en abandono, equivalentes al 74,11 % y 25,89 %, respectivamente.

En la revisión inicial no se encontraron valores faltantes ni registros duplicados, por lo que no se requiere imputación de datos. El cuadro I resume las variables principales del conjunto de datos.

El dataset tiene 12 columnas que mezclan tipos numéricos y categóricos. A continuación se describen las variables predictoras (10 en total, *user_id* no se usará como predictor) y la variable objetivo.

Cuadro I
VARIABLES DEL CONJUNTO DE DATOS SPOTIFY ANALYSIS DATASET 2025

Variable	Tipo	Descripción
<i>user_id</i>	Identificador	Clave única del usuario
<i>gender</i>	Categórica nominal	Hombre / Mujer / Otro
<i>age</i>	Numérica entera	Edad del usuario
<i>country</i>	Categórica nominal	Ubicación geográfica
<i>subscription_type</i>	Categórica nominal	Free, Premium, Family, Student
<i>listening_time</i>	Numérica entera	Minutos promedio de escucha/día
<i>songs_played_per_day</i>	Numérica entera	Canciones reproducidas/día (promedio)
<i>skip_rate</i>	Numérica continua	Porcentaje de canciones omitidas
<i>device_type</i>	Categórica nominal	Mobile, Desktop, Web
<i>ads_listened_per_week</i>	Numérica entera	Número de anuncios por semana
<i>offline_listening</i>	Binaria	Usa modo sin conexión (Sí/No)
<i>is_churned</i>	Binaria	0 = activo, 1 = abandonó

II-C. Consideraciones iniciales del conjunto de datos

Durante la revisión inicial del conjunto de datos se identificaron algunas consideraciones importantes para el análisis. En primer lugar, la variable *offline_listening* se interpreta como una variable binaria, ya que sus valores indican si el usuario utiliza o no la escucha sin conexión. Por tanto, no será tratada como una medida continua de tiempo.

En segundo lugar, la variable objetivo *is_churned* permite distinguir entre usuarios activos y usuarios que abandonaron la plataforma. Sin embargo, el conjunto de datos no incluye una columna que indique el motivo específico de cancelación o abandono. Por esta razón, el análisis se limitará a estudiar asociaciones entre las variables disponibles y el churn, sin establecer relaciones causales directas.

Finalmente, la base de datos no contiene variables temporales, como fechas de registro, fecha de cancelación o historial de actividad por periodo. Esto implica que el modelo propuesto será de tipo estático, basado únicamente en las características disponibles para cada usuario.

II-D. Codificación de variables y paradigma de aprendizaje

Debido a que los modelos de aprendizaje automático requieren variables numéricas, será necesario transformar las variables categóricas del conjunto de datos. Las variables *gender*, *country*, *subscription_type* y *device_type* se codificarán mediante *one-hot encoding*, ya que no presentan un orden numérico natural. La variable *offline_listening* se conservará como variable binaria con valores 0 y 1, mientras que las variables numéricas (*age*, *listening_time*, *songs_played_per_day*, *skip_rate* y *ads_listened_per_week*) se mantendrán en su escala original o serán estandarizadas según el modelo utilizado. La variable *user_id* será excluida, debido a que corresponde únicamente a un identificador.

El problema se aborda bajo el paradigma de aprendizaje supervisado, específicamente como una tarea de clasificación binaria, ya que existe una variable objetivo definida (*is_churned*) que indica si el usuario abandonó o no la plataforma. En las siguientes etapas del proyecto se evaluarán modelos como regresión logística, KNN, Random Forest, red neuronal artificial y SVM, con el fin de comparar su desempeño en la predicción del churn.

III. ESTADO DEL ARTE

La predicción de abandono de usuarios ha sido ampliamente estudiada en servicios digitales basados en suscripción, especialmente en contextos donde la permanencia del usuario afecta directamente los ingresos recurrentes. En plataformas de música en streaming, trabajos recientes han usado conjuntos de datos como KKBox y Sparkify para formular el problema como una tarea de clasificación supervisada, cuyo objetivo es estimar si un usuario abandonará o no el servicio.

Cheng y He [3] propusieron un modelo híbrido basado en redes de atención por grafos y perceptrón multicapa para predecir churn en un servicio de streaming musical. El trabajo utilizó el conjunto de datos KKBox y formuló el problema como clasificación binaria. Su enfoque combinó características individuales de los usuarios con relaciones de similitud representadas mediante un grafo sintético, además de una función de pérdida ponderada para tratar el desbalanceo de clases. El modelo fue evaluado mediante métricas como accuracy, AUC, F1-score, matriz de confusión y análisis ROC, alcanzando una exactitud de 95,8 % y un AUC de 0,9626.

Gregory [6] abordó el problema de predicción de churn en el conjunto de datos KKBox del WSDM Cup 2018 mediante XGBoost e ingeniería de características temporales. El problema fue planteado como clasificación binaria y la evaluación se realizó mediante log loss, métrica oficial de la competencia. El modelo obtuvo un log loss de 0,07974, ubicándose en el primer lugar de la competencia. Este trabajo evidencia la importancia del historial temporal del usuario y de la ingeniería de características en problemas de churn.

Yu et al. [7] propusieron una tubería práctica de aprendizaje automático para el reto de churn de KKBox, incluyendo limpieza de datos, ingeniería de características, submuestreo para tratar el desbalanceo y un modelo de stacking. Los autores emplearon regresión logística, Random Forest y XGBoost como parte de una estrategia de dos etapas con validación tipo 5-fold stacking. La métrica de evaluación fue log loss, y el mejor resultado reportado fue 0,0934, superando configuraciones más simples basadas únicamente en regresión logística o XGBoost.

Schill [8] estudió la predicción de churn en un servicio de streaming en línea, comparando diferentes modelos de clasificación y técnicas para manejar el desbalanceo de clases. El objetivo fue identificar usuarios con probabilidad de cancelar su suscripción dentro de una ventana temporal definida. Aunque se trata de una tesis y no de un artículo de revista, resulta relevante por su cercanía con el problema de este proyecto, ya que aborda directamente servicios de streaming y clasificaciones de abandono.

De manera complementaria, Imani et al. [5] presentan una revisión sistemática reciente sobre predicción de churn con aprendizaje automático y aprendizaje profundo. Los autores analizaron estudios publicados entre 2020 y 2024 en bases como Springer, IEEE, Elsevier, MDPI, ACM y Wiley, encontrando que los métodos de ensamble como XGBoost y LightGBM son dominantes en datos estructurados, mientras que modelos profundos como LSTM y CNN son útiles cuando existen datos secuenciales o no estructurados. También destacan retos comunes como el desbalanceo de clases, la interpretabilidad y la selección de métricas adecuadas.

En síntesis, los antecedentes revisados muestran que la predicción de churn suele abordarse como un problema de clasificación supervisada, donde los modelos no lineales y de ensamble tienden a obtener mejores resultados que modelos lineales simples. Para el presente proyecto, estos trabajos justifican la comparación de modelos como regresión logística, KNN, Random Forest, redes neuronales y SVM. Sin embargo, a diferencia de estudios como KKBox, el conjunto de datos de Spotify utilizado no contiene historial temporal, por lo que el análisis se limitará a variables estáticas de perfil y comportamiento.

REFERENCIAS

- [1] Spotify Technology S.A., "Annual Report 2024," 2025. https://s29.q4cdn.com/175625835/files/doc_financials/2024/ar/Annual-Report-2024.pdf
- [2] N. Zahid, "Spotify Analysis Dataset 2025," Kaggle, 2025. <https://www.kaggle.com/datasets/nabihazahid/spotify-dataset-for-churn-analysis>
- [3] H. Cheng and J. He, "Advanced customer churn prediction for a music streaming digital marketing service using attention graph-based deep learning approach," *Scientific Reports*, vol. 15, article 45028, 2025. doi: 10.1038/s41598-025-28357-z
- [4] N. Montecchio, P. Roy, and F. Pachet, "The skipping behavior of users of music streaming services and its relation to musical structure," *PLOS ONE*, vol. 15, no. 9, 2020. doi: 10.1371/journal.pone.0239418
- [5] M. Imani, M. Joudaki, A. Beikmohammadi, and H. R. Arabnia, "Customer Churn Prediction: A Systematic Review of Recent Advances, Trends, and Challenges in Machine Learning and Deep Learning," *Machine Learning and Knowledge Extraction*, vol. 7, no. 3, 2025.
- [6] B. Gregory, "Predicting Customer Churn: Extreme Gradient Boosting with Temporal Data," WSDM Cup 2018, 2018. <https://arxiv.org/pdf/1802.03396>
- [7] W. Yu et al., "A Practical Pipeline with Stacking Models for KKBOX's Churn Prediction Challenge," WSDM Cup 2018, 2018. https://wsdm-cup-2018.kkbox.events/pdf/7_A_Practical_Pipeline_with_Stacking_Models_for_KKBOXs_Churn_Prediction_Challenge.pdf
- [8] A. Schill, "Customer Churn Prediction in an Online Streaming Service," M.Sc. thesis, Lund University, 2018. <https://lup.lub.lu.se/luur/download?fileId=8971757&func=downloadFile&recordId=8971756>