

Predicción de Abandono de Usuarios en Plataformas de Streaming Musical: Análisis de Factores y Modelos de Machine Learning

Mateo Gaviria Ruiz, Jose Luis Murillo Fernandez, Stiven Alipio Berrío
Estudiantes de Ingeniería de Sistemas
Universidad de Antioquia
Medellín, Colombia

Resumen—El abandono de usuarios (*churn*) representa un desafío relevante para plataformas digitales basadas en suscripción y uso recurrente, ya que afecta la retención de clientes y la estabilidad de los ingresos generados por suscripciones y publicidad. Este proyecto analiza y predice el *churn* en usuarios de Spotify utilizando un conjunto de datos público de Kaggle compuesto por 8.000 registros y 12 variables relacionadas con información demográfica, tipo de suscripción, comportamiento de escucha, uso de dispositivos, anuncios y escucha sin conexión.

El problema se aborda como una tarea de clasificación binaria supervisada, donde la variable objetivo *is_churned* indica si un usuario abandonó o no la plataforma. Para ello, se compararon cinco modelos de aprendizaje automático: Regresión Logística, KNN, Random Forest, MLP y SVM. Además, se evaluó el efecto del manejo moderado del desbalance mediante SMOTE y se aplicaron técnicas de reducción de dimensionalidad lineal y no lineal mediante PCA y UMAP.

Los resultados muestran que la Regresión Logística obtuvo el mejor desempeño promedio en validación cruzada, mientras que SVM presentó el comportamiento más equilibrado en el conjunto de prueba. Sin embargo, los valores de F1-score y AUC-ROC fueron modestos, lo que evidencia una baja capacidad predictiva de las variables disponibles. Ni SMOTE, ni PCA, ni UMAP lograron mejorar de forma consistente los modelos base. En consecuencia, el análisis sugiere que el *dataset* contiene poca señal discriminativa para distinguir usuarios activos y usuarios en abandono, por lo que las variables estudiadas deben interpretarse como factores débilmente asociados al *churn* y no como causas directas de cancelación.

Index Terms—*churn*, Spotify, aprendizaje automático, clasificación binaria, retención de usuarios, PCA, UMAP.

I. INTRODUCCIÓN

Las plataformas de streaming musical han transformado la forma en que los usuarios acceden y consumen contenido digital. Spotify, por ejemplo, opera bajo un modelo que combina usuarios gratuitos con publicidad y usuarios de suscripción premium, por lo que la permanencia y participación continua de los usuarios representa un aspecto importante para la sostenibilidad del servicio [1]. En este contexto, el abandono de usuarios, conocido como *churn*, constituye un problema relevante, ya que puede afectar la retención de clientes, los ingresos recurrentes y las estrategias de fidelización.

La predicción de *churn* ha sido ampliamente abordada mediante técnicas de aprendizaje automático, debido a que permite identificar usuarios con mayor probabilidad de abandonar un servicio y apoyar la toma de decisiones en estrategias

de retención [5]. En plataformas de streaming musical, el comportamiento de uso resulta especialmente importante, ya que variables como el tiempo de escucha, la cantidad de canciones reproducidas, la tasa de omisión (*skip rate*), el tipo de dispositivo y el uso de funcionalidades específicas pueden aportar información sobre el nivel de interacción del usuario con la plataforma [3], [4].

Este proyecto aborda el análisis y la predicción del *churn* en usuarios de Spotify utilizando el conjunto de datos público *Spotify Analysis Dataset 2025*, disponible en Kaggle. Este *dataset* contiene información demográfica, tipo de suscripción, comportamiento de escucha, exposición a anuncios, uso de dispositivos y una variable objetivo denominada *is_churned*, que indica si el usuario abandonó o no la plataforma [2]. Dado que la base de datos no incluye una variable explícita sobre el motivo de cancelación, el propósito del trabajo no es establecer causas directas, sino analizar patrones asociados al abandono y plantear una solución de aprendizaje supervisado para clasificar usuarios activos y usuarios que abandonaron.

El documento se organiza de la siguiente manera: la Sección II presenta la descripción del problema, la composición del conjunto de datos, las variables disponibles, las consideraciones iniciales de preprocesamiento y el paradigma de aprendizaje seleccionado. La Sección III expone una revisión del estado del arte sobre predicción de *churn* en servicios digitales y modelos de aprendizaje automático aplicados a problemas similares. La Sección IV describe la configuración experimental, los modelos evaluados, la selección de hiperparámetros y los resultados obtenidos en entrenamiento, validación y prueba. La Sección V presenta el análisis individual de variables y la reducción de dimensionalidad mediante PCA y UMAP. Finalmente, la Sección VI discute los resultados obtenidos, compara los hallazgos con la literatura revisada y expone las principales conclusiones del proyecto.

II. DESCRIPCIÓN DEL PROBLEMA

II-A. Contexto y utilidad de una solución basada en ML

El abandono de usuarios, conocido como *churn*, es un problema relevante para plataformas digitales como Spotify, ya que afecta la retención de usuarios y la estabilidad de los ingresos generados por suscripciones y publicidad [1]. En este proyecto, el *churn* se aborda como un problema de clasificación binaria, donde se busca predecir si un usuario abandonará

o no la plataforma a partir de variables demográficas, tipo de suscripción y comportamiento de uso [2].

Una solución basada en *Machine Learning* permite identificar patrones asociados al abandono y apoyar futuras estrategias de retención. Sin embargo, como el conjunto de datos no incluye una variable explícita sobre el motivo de cancelación, el análisis no busca establecer causas directas, sino estudiar relaciones entre las características disponibles y la variable objetivo *is_churned*.

II-B. Conjunto de datos

El conjunto de datos utilizado corresponde a *Spotify Analysis Dataset 2025*, disponible en Kaggle [2]. La base contiene 8.000 registros, donde cada fila representa un usuario. Las variables incluyen información demográfica, tipo de suscripción, comportamiento de escucha, dispositivo utilizado, exposición a anuncios, escucha sin conexión y la variable objetivo *is_churned*.

El problema se formula como una tarea de clasificación binaria, donde *is_churned* = 0 representa usuarios activos e *is_churned* = 1 usuarios que abandonaron. La distribución inicial muestra 5.929 usuarios activos y 2.071 usuarios en abandono, equivalentes al 74,11 % y 25,89 %, respectivamente.

En la revisión inicial no se encontraron valores faltantes ni registros duplicados, por lo que no se requiere imputación de datos. La Tabla I resume las variables principales del conjunto de datos.

El *dataset* tiene 12 columnas que mezclan tipos numéricos y categóricos. A continuación se describen las variables predictoras (10 en total, *user_id* no se usará como predictor) y la variable objetivo.

Tabla I
VARIABLES DEL CONJUNTO DE DATOS *Spotify Analysis Dataset 2025*

Variable	Tipo	Descripción
<i>user_id</i>	Identificador	Clave única del usuario.
<i>gender</i>	Categoría nominal	Hombre/Mujer/Otro.
<i>age</i>	Númerica entera	Edad del usuario.
<i>country</i>	Categoría nominal	Ubicación geográfica.
<i>subscription_type</i>	Categoría nominal	Free, Premium, Family, Student.
<i>listening_time</i>	Númerica entera	Minutos promedio de escucha por día.
<i>songs_played_per_day</i>	Númerica entera	Canciones reproducidas por día (promedio).
<i>skip_rate</i>	Númerica continua	Tasa o proporción de canciones omitidas.
<i>device_type</i>	Categoría nominal	Mobile, Desktop, Web.
<i>ads_listened_per_week</i>	Númerica entera	Número de anuncios escuchados por semana.
<i>offline_listening</i>	Binaria	Indica si usa el modo sin conexión.
<i>is_churned</i>	Binaria	0 = activo, 1 = abandonó.

II-C. Consideraciones iniciales del conjunto de datos

Durante la revisión inicial del conjunto de datos se identificaron algunas consideraciones importantes para el análisis. En primer lugar, la variable *offline_listening* se interpreta como una variable binaria, ya que sus valores indican si el usuario utiliza o no la escucha sin conexión. Por tanto, no será tratada como una medida continua de tiempo.

En segundo lugar, la variable objetivo *is_churned* permite distinguir entre usuarios activos y usuarios que abandonaron la plataforma. Sin embargo, el conjunto de datos no incluye una columna que indique el motivo específico de cancelación o abandono. Por esta razón, el análisis se limitará a estudiar asociaciones entre las variables disponibles y el *churn*, sin establecer relaciones causales directas.

Finalmente, la base de datos no contiene variables temporales, como fechas de registro, fecha de cancelación o historial de actividad por periodo. Esto implica que el modelo propuesto será de tipo estático, basado únicamente en las características disponibles para cada usuario.

II-D. Codificación de variables y paradigma de aprendizaje

Debido a que los modelos de aprendizaje automático requieren variables numéricas, será necesario transformar las variables categóricas del conjunto de datos. Las variables *gender*, *country*, *subscription_type* y *device_type* se codificarán mediante *one-hot encoding*, ya que no presentan un orden numérico natural. La variable *offline_listening* se conservará como variable binaria con valores 0 y 1, mientras que las variables numéricas (*age*, *listening_time*, *songs_played_per_day*, *skip_rate* y *ads_listened_per_week*) se mantendrán en su escala original o serán estandarizadas según el modelo utilizado. La variable *user_id* será excluida, debido a que corresponde únicamente a un identificador.

El problema se aborda bajo el paradigma de aprendizaje supervisado, específicamente como una tarea de clasificación binaria, ya que existe una variable objetivo definida (*is_churned*) que indica si el usuario abandonó o no la plataforma. En las siguientes etapas del proyecto se evaluarán modelos como regresión logística, KNN, Random Forest, red neuronal artificial y SVM, con el fin de comparar su desempeño en la predicción del *churn*.

III. ESTADO DEL ARTE

La predicción de abandono de usuarios ha sido ampliamente estudiada en servicios digitales basados en suscripción, especialmente en contextos donde la permanencia del usuario afecta directamente los ingresos recurrentes. En plataformas de música en streaming, trabajos recientes han usado conjuntos de datos como KKBox y Sparkify para formular el problema como una tarea de clasificación supervisada, cuyo objetivo es estimar si un usuario abandonará o no el servicio.

Cheng y He [3] propusieron un modelo híbrido basado en redes de atención por grafos y perceptrón multicapa para predecir *churn* en un servicio de streaming musical. El trabajo utilizó el conjunto de datos KKBox y formuló el problema como clasificación binaria. Su enfoque combinó características individuales de los usuarios con relaciones de similitud representadas mediante un grafo sintético, además de una función de pérdida ponderada para tratar el desbalanceo de clases. El modelo fue evaluado mediante métricas como *accuracy*, AUC, F1-score, matriz de confusión y análisis ROC, alcanzando una exactitud de 95,8 % y un AUC de 0,9626.

Gregory [6] abordó el problema de predicción de *churn* en el conjunto de datos KKBox del WSDM Cup 2018 mediante XGBoost e ingeniería de características temporales.

El problema fue planteado como clasificación binaria y la evaluación se realizó mediante *log loss*, métrica oficial de la competencia. El modelo obtuvo un *log loss* de 0,07974, ubicándose en el primer lugar de la competencia. Este trabajo evidencia la importancia del historial temporal del usuario y de la ingeniería de características en problemas de *churn*.

Yu et al. [7] propusieron una tubería práctica de aprendizaje automático para el reto de *churn* de KKBox, incluyendo limpieza de datos, ingeniería de características, submuestreo para tratar el desbalanceo y un modelo de *stacking*. Los autores emplearon regresión logística, Random Forest y XGBoost como parte de una estrategia de dos etapas con validación tipo 5-fold stacking. La métrica de evaluación fue *log loss*, y el mejor resultado reportado fue 0,0934, superando configuraciones más simples basadas únicamente en regresión logística o XGBoost.

Schill [8] estudió la predicción de *churn* en un servicio de streaming en línea, comparando diferentes modelos de clasificación y técnicas para manejar el desbalanceo de clases. El objetivo fue identificar usuarios con probabilidad de cancelar su suscripción dentro de una ventana temporal definida. Aunque se trata de una tesis y no de un artículo de revista, resulta relevante por su cercanía con el problema de este proyecto, ya que aborda directamente servicios de streaming y clasificaciones de abandono.

De manera complementaria, Imani et al. [5] presentan una revisión sistemática reciente sobre predicción de *churn* con aprendizaje automático y aprendizaje profundo. Los autores analizaron estudios publicados entre 2020 y 2024 en bases como Springer, IEEE, Elsevier, MDPI, ACM y Wiley, encontrando que los métodos de ensamble como XGBoost y LightGBM son dominantes en datos estructurados, mientras que modelos profundos como LSTM y CNN son útiles cuando existen datos secuenciales o no estructurados. También destacan retos comunes como el desbalanceo de clases, la interpretabilidad y la selección de métricas adecuadas.

En síntesis, los antecedentes revisados muestran que la predicción de *churn* suele abordarse como un problema de clasificación supervisada, donde los modelos no lineales y de ensamble tienden a obtener mejores resultados que modelos lineales simples. Para el presente proyecto, estos trabajos justifican la comparación de modelos como regresión logística, KNN, Random Forest, redes neuronales y SVM. Sin embargo, a diferencia de estudios como KKBox, el conjunto de datos de Spotify utilizado no contiene historial temporal, por lo que el análisis se limitará a variables estáticas de perfil y comportamiento.

Tabla II
SÍNTESIS DE TRABAJOS RELACIONADOS EN PREDICCIÓN DE *churn*

Trabajo	Paradigma	Técnicas usadas	Validación / evaluación	Métricas	Resultados
Cheng y He [3]	Supervisado, clasificación binaria	Hybrid GAT + MLP	Evaluación sobre KKBBox, manejo de desbalance con pérdida ponderada	Accuracy, AUC, F1, ROC	Accuracy 95,8 %, AUC 0,9626.
Gregory [6]	Supervisado, clasificación binaria	XGBoost + ingeniería temporal	Competencia WSDM Cup 2018	Log loss	Log loss 0,07974.
Yu et al. [7]	Supervisado, clasificación binaria	Regresión logística, Random Forest, XGBoost, stacking	5-fold stacking y evaluación offline	Log loss	Mejor log loss 0,0934.
Schill [8]	Supervisado, clasificación binaria	Modelos de clasificación y técnicas para desbalance	Comparación experimental de modelos	Métricas de clasificación	Identificación de usuarios propensos a cancelar.
Imani et al. [5]	Revisión sistemática	ML y DL para churn	Revisión PRISMA 2020–2024	Comparación de métricas usadas en la literatura	Identifica tendencias: ensembles, DL, desbalance e interpretabilidad.

IV. ENTRENAMIENTO Y EVALUACIÓN DE LOS MODELOS

IV-A. Configuración experimental

En esta sección se presenta la configuración experimental empleada para entrenar y evaluar los modelos de aprendizaje automático. El objetivo fue comparar diferentes aproximaciones de clasificación supervisada para predecir la variable objetivo *is_churned*, evitando fuga de información entre los conjuntos de entrenamiento y prueba.

Inicialmente se excluyó la variable *user_id*, debido a que corresponde únicamente a un identificador del usuario y no aporta información predictiva generalizable. La variable objetivo fue *is_churned*, donde el valor 0 representa usuarios activos y el valor 1 representa usuarios en condición de abandono.

Las variables categóricas *gender*, *country*, *subscription_type* y *device_type* fueron transformadas mediante *one-hot encoding*. La variable *offline_listening* se conservó como variable binaria con valores 0 y 1. Por su parte, las variables numéricas *age*, *listening_time*, *songs_played_per_day*, *skip_rate* y *ads_listened_per_week* fueron estandarizadas dentro del flujo de preprocesamiento. Estas transformaciones se implementaron mediante un *pipeline*, con el fin de garantizar que el preprocesamiento se ajustara únicamente con los datos de entrenamiento.

El conjunto de datos fue dividido en 80 % para entrenamiento y 20 % para prueba, utilizando una partición estratificada para conservar la proporción original entre usuarios activos y usuarios en abandono. Dentro del conjunto de entrenamiento se aplicó validación cruzada estratificada de 5 pliegues para la selección de hiperparámetros. La métrica principal de optimización fue el F1-score, debido a que el problema presenta un desbalance moderado entre clases y se requiere evaluar simultáneamente precisión y recall. Además, se reportaron accuracy, precisión, recall y AUC-ROC para analizar el desempeño desde diferentes perspectivas.

Se evaluaron cinco modelos principales, cubriendo las categorías requeridas por el proyecto: Regresión Logística como modelo paramétrico, KNN como modelo no paramétrico, Random Forest como ensamble de árboles de decisión, MLP como red neuronal artificial y SVM como máquina de vectores de soporte.

Adicionalmente, se realizó un experimento complementario con SMOTE moderado para evaluar si el desbalance de clases

afectaba de forma significativa el desempeño. SMOTE se aplicó únicamente sobre los datos de entrenamiento y dentro del *pipeline* de validación, evitando que la información del conjunto de prueba influyera en el proceso de entrenamiento.

IV-B. Hiperparámetros evaluados

La Tabla III resume los principales hiperparámetros analizados para cada modelo durante el proceso de validación cruzada.

Tabla III
HIPERPARÁMETROS EVALUADOS

Modelo	Hiperparámetros evaluados
Regresión Logística	$C \in \{0,01, 0,1, 1, 10\}$ y penalización L1 o L2; se utilizó <code>class_weight="balanced"</code> .
KNN	$n_neighbors \in \{11, 21, 31, 51\}$, ponderación <code>uniform</code> o <code>distance</code> , y distancia $p \in \{1, 2\}$.
Random Forest	$n_estimators = 200$, $max_depth \in \{3, 5, 8, 12\}$, $min_samples_leaf \in \{5, 10\}$, $max_features = \text{sqrt}$ y $class_weight \in \{\text{balanced}, \text{balanced_subsample}\}$.
MLP	Capas ocultas (16.), (32.), (32,16), $alpha \in \{0,001, 0,01, 0,1\}$ y $learning_rate_init = 0,001$.
SVM	$C \in \{0,1, 1, 10\}$, kernel RBF, $gamma \in \{\text{scale}, 0,01, 0,1\}$; se utilizó <code>class_weight="balanced"</code> .

IV-C. Resultados de los modelos base

La Tabla IV presenta los resultados principales obtenidos por los modelos base. Se reporta el F1-score promedio en validación cruzada, el F1-score en el conjunto de prueba, el recall para la clase de abandono y el AUC-ROC.

Tabla IV
RESULTADOS DE LOS MODELOS BASE

Modelo	F1-CV	F1 test	Recall	AUC
Reg. Logística	0.3537 $\pm$ 0.0113	0.3449	0.4903	0.4967
SVM	0.3419 $\pm$ 0.0065	0.3561	0.4976	0.5331
Random Forest	0.3325 $\pm$ 0.0103	0.3167	0.4227	0.4870
KNN	0.0766 $\pm$ 0.0092	0.0943	0.0556	0.5174
MLP	0.0117 $\pm$ 0.0130	0.0048	0.0024	0.5086

Los resultados muestran que la Regresión Logística obtuvo el mejor desempeño promedio durante la validación cruzada,

con un F1-score de 0.3537 ± 0.0113 . Sin embargo, en el conjunto de prueba, el modelo SVM presentó el mejor equilibrio general, alcanzando un F1-score de 0.3561, recall de 0.4976 y AUC de 0.5331.

Aunque estos valores son modestos, SVM fue considerado el modelo base más equilibrado, ya que logró detectar cerca de la mitad de los usuarios en condición de abandono sin favorecer de forma tan extrema una única clase. Por su parte, la Regresión Logística presentó un comportamiento estable en validación cruzada, lo que indica que los modelos más simples lograron un rendimiento comparable o superior al de modelos más flexibles.

El modelo MLP obtuvo una exactitud relativamente alta, pero un F1-score y un recall muy bajos para la clase de abandono. Esto indica que el modelo tendió a favorecer la clase mayoritaria, clasificando la mayoría de los casos como usuarios activos. Por esta razón, la exactitud no fue considerada como métrica principal, ya que puede resultar engañosa en presencia de desbalance de clases.

Asimismo, modelos como KNN y Random Forest no lograron superar de forma consistente a la Regresión Logística o SVM. Esto sugiere que las variables disponibles no contienen patrones suficientemente diferenciables para que modelos más complejos logren una mejora clara en la predicción del *churn*.

IV-D. Experimento con SMOTE moderado

Con el fin de evaluar si el desbalance moderado entre usuarios activos y usuarios en abandono afectaba el desempeño de los modelos, se realizó un experimento adicional con SMOTE. Esta técnica genera ejemplos sintéticos de la clase minoritaria a partir de los datos de entrenamiento. En este trabajo se utilizó una estrategia moderada, evitando balancear completamente las clases para no alterar de forma agresiva la distribución original del problema.

La Tabla V resume los principales resultados obtenidos con SMOTE moderado.

Tabla V
RESULTADOS CON SMOTE MODERADO

Modelo	F1-CV	F1 test	Recall	AUC
KNN + SMOTE	0.1824	0.1844	0.1425	0.5251
SVM + SMOTE	0.1562	0.2219	0.1618	0.5368
MLP + SMOTE	0.0262	0.0000	0.0000	0.5124
Reg. Log. + SMOTE	0.0000	0.0000	0.0000	0.5000
Random F. + SMOTE	0.0000	0.0000	0.0000	0.4988

Los resultados indican que SMOTE moderado no produjo mejoras consistentes frente a los modelos base. En algunos casos, el desempeño incluso disminuyó, especialmente en Regresión Logística, Random Forest y MLP. Aunque SVM + SMOTE presentó un AUC ligeramente superior al SVM base, su F1-score y recall fueron inferiores. Por tanto, el uso de SMOTE no fue adoptado como configuración principal.

Este resultado sugiere que el bajo desempeño de los modelos no se explica únicamente por el desbalance de clases, sino también por la limitada capacidad discriminativa de las variables disponibles en el conjunto de datos.

IV-E. Ajuste del umbral de clasificación

Adicionalmente, se evaluó un ajuste del umbral de clasificación para analizar el compromiso entre precisión y recall. En lugar de utilizar el umbral estándar de 0.5, se exploraron diferentes valores con el objetivo de maximizar el F1-score.

El ajuste de umbral permitió aumentar el F1-score hasta valores cercanos a 0.41. Sin embargo, este incremento se logró a costa de clasificar casi todos los usuarios como *churn*, lo que generó un recall muy alto, pero una precisión baja y una disminución considerable de la exactitud.

Por esta razón, el ajuste de umbral se interpreta como un experimento útil para comprender el compromiso entre recall y precisión, pero no como la mejor solución final. Para el objetivo del proyecto, se prefirió conservar como referencia el modelo base SVM, ya que presentó un comportamiento más equilibrado.

IV-F. Discusión de los resultados de modelado

En general, los resultados obtenidos muestran que la predicción de *churn* en este conjunto de datos es una tarea compleja. Aunque se evaluaron diferentes familias de modelos, incluyendo modelos lineales, no paramétricos, ensambles, redes neuronales y máquinas de vectores de soporte, ninguno logró un desempeño alto en términos de F1-score o AUC-ROC.

Los valores de AUC cercanos a 0.5 indican que los modelos tienen una capacidad limitada para separar usuarios activos de usuarios en condición de abandono. Esta observación es consistente con el análisis exploratorio, donde las diferencias entre clases fueron reducidas tanto en variables numéricas como categóricas.

Por tanto, los resultados sugieren que las variables disponibles permiten realizar un análisis comparativo inicial, pero no contienen suficiente información para construir un clasificador robusto de *churn*. Esta limitación puede deberse a la ausencia de variables temporales o históricas, como frecuencia reciente de uso, antigüedad del usuario, historial de pagos, fecha de cancelación o cambios en el patrón de escucha.

En consecuencia, el modelo SVM base se considera la mejor alternativa dentro de los modelos evaluados, no porque alcance un desempeño alto, sino porque ofrece el mejor equilibrio relativo entre F1-score, recall y AUC en el conjunto de prueba.

V. REDUCCIÓN DE DIMENSIÓN

V-A. Análisis individual de variables

Antes de aplicar técnicas de reducción de dimensión, se realizó un análisis individual de las variables con el objetivo de identificar si alguna característica presentaba una capacidad discriminativa clara frente a la variable objetivo *is_churned*. Para las variables numéricas se compararon las medias entre usuarios activos y usuarios en abandono, utilizando pruebas estadísticas de diferencia de medias. Para las variables categóricas y binarias se analizaron las tasas de *churn* por categoría y se aplicaron pruebas de independencia.

La Tabla VI resume los principales resultados obtenidos para las variables numéricas.

Tabla VI
ANÁLISIS INDIVIDUAL DE VARIABLES NUMÉRICAS

Variable	Activos	Churn	Dif.	p-value
<i>skip_rate</i>	0.298	0.305	0.006	0.1505
<i>songs_played_per_day</i>	49.971	50.576	0.605	0.4040
<i>listening_time</i>	154.447	152.985	-1.462	0.4924
<i>age</i>	37.632	37.748	0.116	0.7209
<i>ads_listened_per_week</i>	6.962	6.891	-0.071	0.8393

Los resultados muestran que las diferencias entre usuarios activos y usuarios en abandono son reducidas para todas las variables numéricas. Además, los valores de significancia obtenidos no evidencian diferencias fuertes entre ambos grupos. Esto sugiere que, de manera individual, las variables numéricas no separan claramente las clases del problema.

En el caso de las variables categóricas, también se observaron variaciones moderadas o pequeñas en la tasa de *churn*. Por ejemplo, en *subscription_type*, las tasas oscilaron aproximadamente entre 24.93 % y 27.52 %. En *device_type*, las tasas estuvieron entre 25.05 % y 26.89 %, mientras que en *offline_listening* la diferencia entre usuarios con y sin escucha sin conexión fue cercana a un punto porcentual. Estos resultados indican que ninguna variable categórica o binaria presenta, por sí sola, una separación marcada entre usuarios activos y usuarios en abandono.

Por esta razón, no se eliminó ninguna variable antes del entrenamiento principal de los modelos. Se decidió conservar todas las variables predictoras válidas, excepto *user_id*, y evaluar posteriormente si técnicas de reducción de dimensión como PCA y UMAP podían simplificar la representación de los datos sin deteriorar el desempeño predictivo.

V-B. Extracción lineal de características mediante PCA

Para evaluar una reducción lineal de las características, se aplicó Análisis de Componentes Principales, conocido como PCA. Esta técnica transforma las variables originales en un nuevo conjunto de componentes no correlacionados, ordenados según la cantidad de varianza que explican.

Después de aplicar el preprocesamiento, el conjunto de datos quedó representado por 20 variables codificadas. Se seleccionó como criterio conservar el 95 % de la varianza acumulada, lo que permitió reducir la representación a 15 componentes principales. Esto equivale a una reducción aproximada del 25 % en la dimensionalidad.

De acuerdo con los resultados de la sección anterior, los dos modelos seleccionados para evaluar PCA fueron Regresión Logística y SVM, ya que presentaron el mejor comportamiento relativo entre los modelos base. La Tabla VII muestra los resultados obtenidos.

Tabla VII
RESULTADOS CON PCA

Modelo	Comp.	Red.	F1	Recall	AUC
Reg. Logística	15	25 %	0.3232	0.4614	0.4831
SVM	15	25 %	0.3393	0.5000	0.4963

Los resultados muestran que PCA permitió reducir la dimensionalidad del conjunto de datos, pero no mejoró el

desempeño predictivo frente a los modelos base. En el caso de Regresión Logística, el F1-score en prueba disminuyó de 0.3449 a 0.3232. Para SVM, el F1-score pasó de 0.3561 a 0.3393. Aunque la reducción fue moderada, la pérdida de desempeño indica que PCA no aportó una ventaja clara para este conjunto de datos.

Por tanto, PCA puede considerarse útil como herramienta de simplificación de la representación, pero no como una mejora del sistema predictivo final.

V-C. Extracción no lineal de características mediante UMAP

Como técnica de reducción no lineal se utilizó UMAP, cuyo objetivo es construir una representación de menor dimensión preservando relaciones locales entre las observaciones. A diferencia de PCA, UMAP no asume una transformación lineal de las variables, por lo que puede capturar estructuras más complejas en los datos.

Para este experimento se seleccionaron 2 componentes, con el fin de evaluar una reducción fuerte de la dimensionalidad y permitir una representación compacta del conjunto de datos. Al pasar de 20 variables codificadas a 2 componentes, se alcanzó una reducción aproximada del 90 %.

La Tabla VIII presenta los resultados obtenidos al evaluar nuevamente Regresión Logística y SVM sobre la representación generada por UMAP.

Tabla VIII
RESULTADOS CON UMAP

Modelo	Comp.	Red.	F1	Recall	AUC
Reg. Logística	2	90 %	0.0926	0.0556	0.4921
SVM	2	90 %	0.0675	0.0386	0.5265

Los resultados muestran que UMAP deterioró de manera considerable el desempeño de los modelos. Aunque logró una reducción dimensional mucho mayor que PCA, los valores de F1-score y recall disminuyeron significativamente. Además, durante la experimentación se observaron señales de sobreajuste, ya que los modelos alcanzaban buenos resultados en entrenamiento pero no generalizaban adecuadamente al conjunto de prueba.

Por lo anterior, UMAP no resultó adecuado para este conjunto de datos en la configuración evaluada. La reducción a 2 componentes fue demasiado agresiva para conservar información útil para la predicción del *churn*.

V-D. Discusión de la reducción de dimensión

Los resultados de reducción de dimensión indican que ninguna de las técnicas evaluadas mejoró el desempeño de los modelos base. PCA logró reducir la dimensionalidad de forma moderada, conservando una parte importante de la varianza, pero produjo una ligera disminución del F1-score. UMAP, por su parte, redujo fuertemente la dimensionalidad, pero deterioró de forma considerable la capacidad predictiva.

Estos resultados son consistentes con el análisis individual de variables y con el desempeño de los modelos base. En general, el conjunto de datos presenta poca separación entre

usuarios activos y usuarios en abandono. Por ello, al reducir la dimensionalidad, especialmente de forma agresiva, se pierde información que, aunque débil, podía ser aprovechada parcialmente por los modelos.

En consecuencia, para este problema se considera más adecuado conservar la representación original preprocesada que utilizar PCA o UMAP como entrada principal del modelo final. No obstante, ambos métodos fueron útiles para evaluar la complejidad de la representación y confirmar que la dificultad principal del problema no está únicamente en la cantidad de variables, sino en la baja capacidad discriminativa de la información disponible.

VI. DISCUSIÓN Y CONCLUSIONES

Los resultados obtenidos muestran que la predicción de *churn* en el conjunto de datos analizado es una tarea compleja. Aunque se evaluaron diferentes familias de modelos de aprendizaje supervisado, incluyendo Regresión Logística, KNN, Random Forest, MLP y SVM, ninguno alcanzó un desempeño alto en términos de F1-score o AUC-ROC. Esto sugiere que las variables disponibles presentan una capacidad limitada para separar claramente a los usuarios activos de los usuarios en condición de abandono.

El mejor desempeño promedio en validación cruzada fue obtenido por la Regresión Logística, con un F1-score de 0.3537 ± 0.0113 . Sin embargo, en el conjunto de prueba, SVM presentó el comportamiento más equilibrado, alcanzando un F1-score de 0.3561, recall de 0.4976 y AUC de 0.5331. Aunque estos valores son modestos, SVM fue considerado el modelo base más adecuado dentro de los evaluados, debido a que logró un balance relativo entre la detección de usuarios en abandono y el control de falsos positivos.

El experimento con SMOTE moderado permitió evaluar si el desbalance de clases era una de las principales causas del bajo rendimiento. No obstante, esta técnica no produjo mejoras consistentes frente a los modelos base. En algunos casos, el desempeño disminuyó o el modelo tendió a favorecer excesivamente una de las clases. Esto indica que el problema no se explica únicamente por la proporción entre usuarios activos y usuarios en abandono, sino también por la baja relación entre las variables disponibles y la variable objetivo *is_churned*.

De igual forma, el ajuste del umbral de clasificación aumentó el F1-score hasta valores cercanos a 0.41, pero lo hizo a costa de clasificar casi todos los usuarios como *churn*. Esto generó un recall muy alto, pero una precisión baja y una reducción considerable de la exactitud. Por esta razón, este ajuste se interpretó como un experimento complementario para analizar el compromiso entre precisión y recall, pero no como la mejor solución final.

En cuanto a la reducción de dimensión, PCA logró reducir la representación de 20 variables codificadas a 15 componentes, pero no mejoró el desempeño predictivo. UMAP, por su parte, redujo la representación a 2 componentes, pero deterioró significativamente el F1-score y mostró señales de sobreajuste. Estos resultados sugieren que la dificultad principal del problema no está en la cantidad de variables, sino en la baja capacidad discriminativa de la información disponible.

Al comparar estos resultados con los trabajos revisados en el estado del arte, se observa una diferencia importante. Estudios como los desarrollados sobre KKBox reportan desempeños superiores utilizando información temporal, historial de actividad, transacciones, registros de escucha y técnicas avanzadas de ingeniería de características [3], [6], [7]. En contraste, el *dataset* utilizado en este proyecto es estático y no contiene variables como fecha de registro, antigüedad del usuario, historial de pagos, evolución del consumo o fecha de cancelación. Esta diferencia puede explicar por qué los modelos evaluados no alcanzaron resultados similares a los reportados en la literatura.

En conclusión, aunque el proyecto permitió aplicar de manera completa una metodología de aprendizaje automático para la predicción de *churn*, los resultados indican que el conjunto de datos posee baja señal predictiva. Las variables analizadas pueden interpretarse como factores débilmente asociados al abandono, pero no como causas directas de cancelación. Para mejorar el desempeño en trabajos futuros, sería recomendable contar con variables temporales e históricas que permitan modelar la evolución del comportamiento del usuario, tales como frecuencia reciente de uso, cambios en el tiempo de escucha, historial de pagos, antigüedad en la plataforma, interacción con recomendaciones y fecha real de cancelación.

REFERENCIAS

- [1] Spotify Technology S.A., "Annual Report 2024," 2025. [En línea]. Disponible: https://s29.q4cdn.com/175625835/files/doc_financials/2024/ar/Annual-Report-2024.pdf
- [2] N. Zahid, "Spotify Analysis Dataset 2025," Kaggle, 2025. [En línea]. Disponible: <https://www.kaggle.com/datasets/nabihazahid/spotify-dataset-for-churn-analysis>
- [3] H. Cheng and J. He, "Advanced customer churn prediction for a music streaming digital marketing service using attention graph-based deep learning approach," *Scientific Reports*, vol. 15, article 45028, 2025. doi: 10.1038/s41598-025-28357-z.
- [4] N. Montecchio, P. Roy, and F. Pachet, "The skipping behavior of users of music streaming services and its relation to musical structure," *PLOS ONE*, vol. 15, no. 9, 2020. doi: 10.1371/journal.pone.0239418.
- [5] M. Imani, M. Joudaki, A. Beikmohammadi, and H. R. Arabnia, "Customer Churn Prediction: A Systematic Review of Recent Advances, Trends, and Challenges in Machine Learning and Deep Learning," *Machine Learning and Knowledge Extraction*, vol. 7, no. 3, 2025.
- [6] B. Gregory, "Predicting Customer Churn: Extreme Gradient Boosting with Temporal Data," WSDM Cup 2018, 2018. [En línea]. Disponible: <https://arxiv.org/pdf/1802.03396>
- [7] W. Yu et al., "A Practical Pipeline with Stacking Models for KKBOX's Churn Prediction Challenge," WSDM Cup 2018, 2018. [En línea]. Disponible: https://wddm-cup-2018.kkbox.events/pdf/7_A_Practical_Pipeline_with_Stacking_Models_for_KKBOXs_Churn_Prediction_Challenge.pdf
- [8] A. Schill, "Customer Churn Prediction in an Online Streaming Service," M.Sc. thesis, Lund University, 2018. [En línea]. Disponible: <https://lup.lub.lu.se/luur/download?fileOId=8971757&func=downloadFile&recordOId=8971756>